Uso de Redes Neurais Híbridas CNN–BiLSTM para o Reconhecimento Automático de Gestos Isolados em Libras

Túlio Castro Silva[1], **Pedro Henrique Calais Guerra**[2]

[1]Ibmec Belo Horizonte

Abstract. *This work presents a system for isolated sign recognition in Brazilian Sign Language (Libras) based on a CNN-BiLSTM architecture using only hand landmarks extracted with MediaPipe. The model uses 126 features per frame and was evaluated on a dataset of 55 signs, achieving 99.3% accuracy with only 446 thousand parameters, enabling real-time execution on a standard CPU. The results indicate that landmark-based representations are sufficient for efficient recognition, supporting low-cost automatic translation applications.*

Resumo. *Este trabalho apresenta um sistema de reconhecimento de sinais isolados da Língua Brasileira de Sinais (Libras) baseado em arquitetura CNN-BiLSTM utilizando apenas landmarks das mãos extraídos pelo MediaPipe. O modelo usa 126 características por frame e foi avaliado em 55 sinais, alcançando acurácia de 99,3% com apenas 446 mil parâmetros, permitindo execução em tempo real em CPU. Os resultados indicam que landmarks são suficientes para reconhecimento eficiente, viabilizando aplicações de baixo custo.*

1. Introdução

1.1. Contexto e motivação

A Língua Brasileira de Sinais (Libras) é o principal meio de comunicação da comunidade surda no Brasil, composta por um conjunto estruturado de gestos manuais, expressões faciais e movimentos corporais. Assim como outras línguas de sinais, a Libras possui gramática e léxico próprios, distintos da língua oral e escrita, exigindo conhecimento específico para sua interpretação. Entretanto, grande parte da população não domina Libras, o que cria barreiras significativas de comunicação entre pessoas surdas e ouvintes [1, 2].

Segundo dados do IBGE [3], aproximadamente 2,3 milhões de pessoas possuem algum grau de surdez no Brasil. No entanto, apenas cerca de 1,8% daquela população com dificuldade auditiva afirma saber usar Libras para se comunicar; entre pessoas com surdez profunda, esse percentual chega a 34% [4]. Esses números ilustram a grande lacuna existente entre a população que necessita da Libras e quem, de fato, tem acesso a ela.

Nesse contexto, sistemas automáticos de reconhecimento de sinais têm se destacado como ferramentas tecnológicas capazes de promover inclusão social, ao possibilitar a tradução ou transcrição em tempo quase real da língua de sinais para a língua oral ou escrita. O avanço de técnicas de *Visão Computacional* e *Aprendizado Profundo* (*Deep Learning*) tem permitido extrair e processar características visuais complexas a partir de imagens ou vídeos com alta precisão [5]. No entanto, muitos modelos de alto desempenho dependem de arquiteturas multimodais complexas e pesadas, o que dificulta sua aplicação em dispositivos de baixo custo ou em cenários de uso embarcado.

1.2. Objetivo

Desenvolver um **sistema comercialmente viável**, leve e de **baixa latência**, capaz de reconhecer **sinais de Libras e gestos manuais**em **tempo real**a partir de vídeo. O sistema seguirá uma arquitetura modular que combina (*i*) extração eficiente de *landmarks* de mãos executada no dispositivo (*on-device*) e (*ii*) uma cabeça de reconhecimento temporal compacta (p. ex., CNN/TCN/BiLSTM enxutas). Para a etapa de detecção e rastreamento de mãos, adotaremos *pipelines* otimizados como *MediaPipe Hands*/Hand Landmarker, projetados para **execução em tempo real em CPUs/GPUs móveis**[6, 7]. A modelagem temporal será ajustada para operação embarcada, preservando desempenho e custo computacional reduzido.

2. Revisão de Literatura

2.1. Abordagens Tradicionais

As primeiras pesquisas em reconhecimento de língua de sinais utilizavam dispositivos sensorizados, como luvas instrumentadas, para capturar posições e movimentos das mãos. Métodos estatísticos como Modelos de Markov Ocultos (HMM) e *Dynamic Time Warping* (DTW) eram amplamente empregados para modelar sequências temporais. Embora eficazes em cenários controlados, essas abordagens dependiam de extração manual de características, segmentação prévia dos gestos e apresentavam limitações de escalabilidade [5].

2.2. Abordagens Baseadas em Visão Computacional

Com o avanço do *deep learning*, tornou-se viável reconhecer gestos diretamente de imagens e vídeos. Redes Convolucionais (CNNs) passaram a extrair automaticamente características espaciais, enquanto LSTMs e arquiteturas híbridas CNN+LSTM foram utilizadas para modelar a dinâmica temporal. Trabalhos recentes indicam que mecanismos de atenção podem melhorar o desempenho ao enfatizar quadros mais informativos [16].

2.3. Reconhecimento em Libras

No contexto brasileiro, estudos como [17] e [18] exploraram combinações de CNNs, LSTMs e representações baseadas em *landmarks*, destacando desafios de generalização entre diferentes conjuntos de dados. Entre os *datasets* nacionais, destaca-se o **MINDS-Libras** [9], composto por sinais isolados capturados em condições controladas, com múltiplos participantes e anotações multimodais. Apesar dos avanços, ainda persistem limitações relacionadas à robustez em ambientes variados e à escassez de bases públicas amplas [17, 18, 10].

2.4. Reconhecimento em ASL

Internacionalmente, a ASL possui conjuntos de dados de larga escala, como **MS-ASL** [11] e **WLASL** [12], que permitiram o treinamento de modelos profundos mais robustos. Bases mais recentes, como **ASL Citizen** [13], ampliaram a diversidade de participantes e cenários, melhorando o desempenho dos modelos. Para sinais contínuos e tradução automática, destacam-se os conjuntos **How2Sign** [14] e **OpenASL** [15], que possibilitam o uso de arquiteturas baseadas em *transformers*. Esses recursos têm impulsionado o estado da arte e servido como referência para pesquisas em outras línguas de sinais.

De modo geral, a literatura aponta que abordagens baseadas em visão computacional e aprendizado profundo têm elevado significativamente a precisão no reconhecimento de sinais, embora desafios de generalização, diversidade de dados e robustez em cenários reais ainda permaneçam.

3. Metodologia

O fluxo metodológico foi estruturado em três etapas: (i) coleta e representação dos dados; (ii) normalização e aumento de dados; (iii) modelagem, treinamento e avaliação do classificador.

3.1. Coleta e Representação dos Dados

O dataset foi obtido por aquisição controlada, com diferentes participantes realizando sinais isolados de Libras. As gravações foram feitas com fundo neutro e iluminação uniforme, em 720p (16:9) a 30 FPS.

As características foram extraídas com o **MediaPipe Hands (Hand Landmarker)**[1], que detecta **21 *landmarks*** 3D por mão. Cada *frame* é representado por coordenadas (x, y, z). A Figura 1 ilustra a indexação.

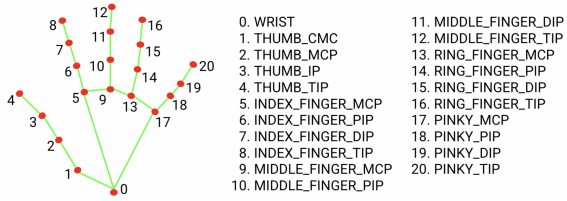

Figura 1. Exemplo de detecção e indexação dos 21 *landmarks* pelo MediaPipe Hands [8].

Para uma mão, o vetor do *frame* f é:

$$\mathbf{L}_f = [(x_0, y_0, z_0), \ldots, (x_{20}, y_{20}, z_{20})]. \tag{1}$$

Para duas mãos, utilizou-se concatenação:

$$\mathbf{V}_f = [\mathbf{L}_f^D \parallel \mathbf{L}_f^E], \tag{2}$$

onde D e E representam mão direita e esquerda. Quando apenas uma mão foi detectada, aplicou-se *zero-padding* para manter dimensionalidade constante ($126 = 2 \times 21 \times 3$). Exemplos 2D/3D são mostrados na Figura 2.

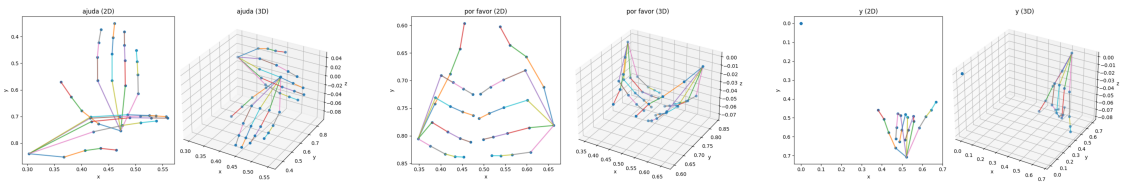

(a) "ajuda". **(b) "por favor".** **(c) "y".**

Figura 2. Exemplos de *landmarks* em projeções 2D/3D para três gestos.

[1]Disponível em: `https://developers.google.com/mediapipe`

3.2. Base de Dados

A base principal foi a **MINDS-Libras** [10], composta por vídeos padronizados de sinais isolados e metadados (sinal e participante), permitindo particionamento controlado. Além disso, foi adicionado um conjunto complementar com **alfabeto manual, pronomes e expressões frequentes**, visando ampliar o vocabulário e avaliar gestos curtos/discretos. A Tabela 1 resume os sinais, origem, número de mãos e natureza (estático vs. movimento).

Tabela 1. Sinais e gestos utilizados, origem, quantidade de mãos e natureza.

Item	Origem	Mãos	Nat.
Acontecer	MINDS	Duas	Mov.
Aluno	MINDS	Uma	Est.
Amarelo	MINDS	Uma	Mov.
América	MINDS	Duas	Est.
Aproveitar	MINDS	Uma	Mov.
Bala	MINDS	Uma	Mov.
Banco	MINDS	Uma	Mov.
Banheiro	MINDS	Duas	Mov.
Barulho	MINDS	Uma	Mov.
Cinco	MINDS	Uma	Est.
Conhecer	MINDS	Uma	Mov.
Espelho	MINDS	Uma	Mov.
Esquina	MINDS	Duas	Mov.
Filho	MINDS	Uma	Mov.
Maçã	MINDS	Uma	Mov.
Medo	MINDS	Uma	Mov.
Ruim	MINDS	Uma	Mov.
Sapo	MINDS	Duas	Mov.
Vacina	MINDS	Uma	Mov.
Vontade	MINDS	Uma	Mov.
a	Adic.	Uma	Est.
ajuda	Adic.	Duas	Mov.
b	Adic.	Uma	Est.
c	Adic.	Uma	Est.
d	Adic.	Uma	Est.
e	Adic.	Uma	Est.
eu	Adic.	Uma	Est.
f	Adic.	Uma	Est.
g	Adic.	Uma	Est.
h	Adic.	Uma	Est.
i	Adic.	Uma	Est.
j	Adic.	Uma	Mov.
k	Adic.	Uma	Est.
l	Adic.	Uma	Est.
m	Adic.	Uma	Est.
n	Adic.	Uma	Est.
não	Adic.	Uma	Mov.
o	Adic.	Uma	Est.
p	Adic.	Uma	Est.
por favor	Adic.	Duas	Mov.
q	Adic.	Uma	Est.
qual	Adic.	Uma	Mov.
quer	Adic.	Uma	Mov.
r	Adic.	Uma	Est.
s	Adic.	Uma	Est.
sim	Adic.	Uma	Mov.
t	Adic.	Uma	Est.
tudo bem	Adic.	Duas	Mov.
u	Adic.	Uma	Est.
v	Adic.	Uma	Est.
você	Adic.	Uma	Mov.
w	Adic.	Uma	Mov.
x	Adic.	Uma	Mov.
y	Adic.	Uma	Mov.
z	Adic.	Uma	Mov.

Abreviações: Nat. = natureza do sinal; Mov. = sinal com movimento; Est. = sinal estático; Adic. = sinal adicionado ao conjunto original.

3.3. Normalização e Aumento de Dados

As sequências foram padronizadas por *z-score* usando estatísticas calculadas apenas no treino:

$$\hat{x}_{i,d} = \frac{x_{i,d} - \mu_d}{\sigma_d}. \tag{3}$$

No treino, aplicou-se *data augmentation* leve (espacial e temporal): *jitter* gaussiano, rotação no plano (x, y), *scaling*, *temporal dropout* e *time mask*. A sequência $X \in R^{T \times F}$ (com $F = 3P$) é reestruturada para $X^{(3)} \in R^{T \times P \times 3}$ para aplicar as transformações e, ao final, é reformatada para o vetor original.

3.4. Modelagem e Arquitetura da Rede BiLSTM

O classificador utiliza uma **BiLSTM** para capturar dependências temporais em ambas as direções:

$$h_t^{\rightarrow} = \mathrm{LSTM}_{\mathrm{fwd}}(x_t, h_{t-1}^{\rightarrow}), h_t^{\leftarrow} = \mathrm{LSTM}_{\mathrm{bwd}}(x_t, h_{t+1}^{\leftarrow}), h_t = [h_t^{\rightarrow};\, h_t^{\leftarrow}] \tag{4}$$

Na implementação, foram usadas duas camadas BiLSTM (128 e 64 unidades), seguidas de uma camada densa (128 neurônios, ReLU), *dropout* e uma saída *softmax* para $K = 55$ classes.

3.5. Treinamento e Validação

O particionamento foi estratificado por classe com isolamento por grupo (*signer*/sessão), evitando que amostras do mesmo grupo apareçam em treino e validação. Fixou-se validação em 20%. As sequências foram ajustadas para um comprimento T via *pad/crop* e normalizadas com estatísticas do treino. O treino usa AdamW (taxa inicial 3×10^{-4}, *weight decay* 10^{-4}), *ReduceLROnPlateau* e *EarlyStopping*. O melhor modelo foi salvo via `ModelCheckpoint`, e as sementes e estatísticas de normalização foram registradas para reprodutibilidade.

4. Resultados

4.1. Acurácia e perda

As Figuras 3 e 4 mostram a evolução de acurácia e perda em treino/validação para o BiLSTM e o LSTM unidirecional. O BiLSTM converge rapidamente e atinge desempenho superior, enquanto o LSTM apresenta dinâmica semelhante, porém com platô ligeiramente inferior (Seção 4.4).

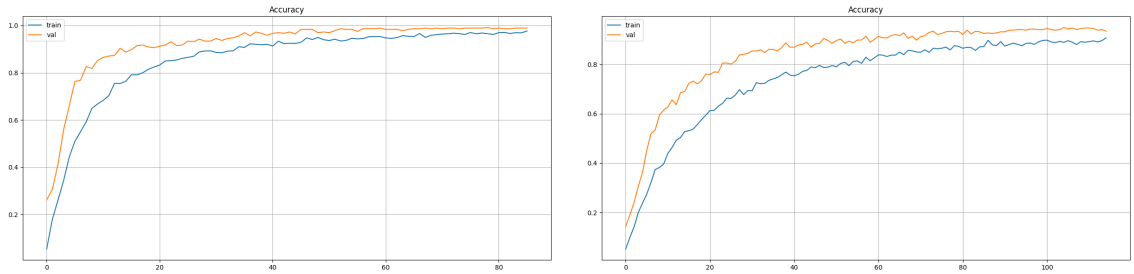

(a) BiLSTM **(b) LSTM unidirecional**

Figura 3. Evolução da acurácia no treino e validação.

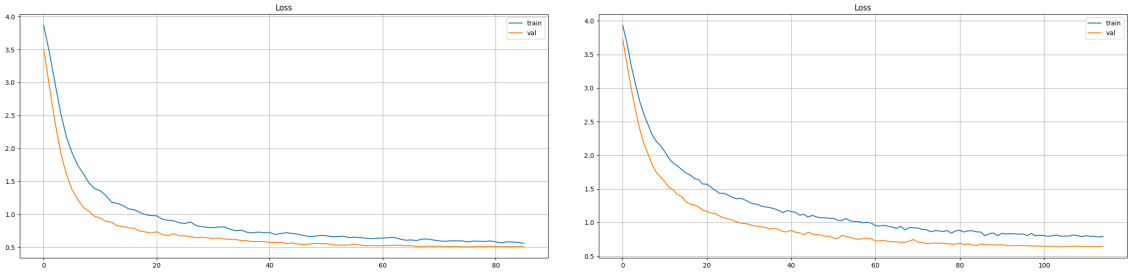

(a) BiLSTM **(b) LSTM unidirecional**

Figura 4. Evolução da perda no treino e validação.

4.2. Curvas e métricas complementares

O BiLSTM apresenta métricas próximas do ideal (AP/AUC elevadas) e o LSTM tem pequena redução, coerente com as métricas agregadas apresentadas adiante.

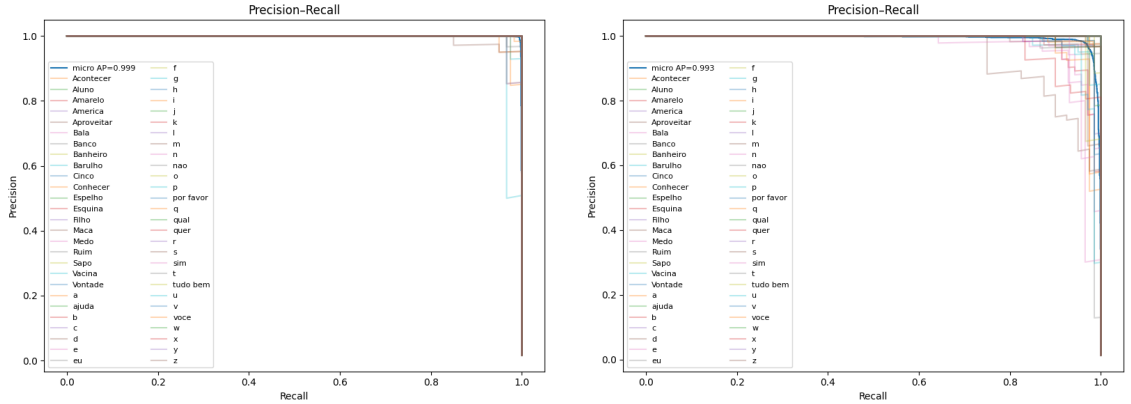

(a) BiLSTM **(b) LSTM unidirecional**

Figura 5. Curvas Precisão–Revocação por classe.

(a) BiLSTM **(b) LSTM unidirecional**

Figura 6. Histograma das confianças das predições.

4.3. Comparação com trabalhos anteriores

A Tabela 2 compara os resultados no MINDS com trabalhos prévios (média $\pm$ desvio padrão). A Tabela 3 reporta o desempenho no cenário com MINDS + sinais adicionados.

Tabela 2. Resultados no dataset MINDS e comparação com trabalhos prévios (média $\pm$ desvio padrão).

Método	Dataset	Acurácia	Precisão	Recall	F1-score
Nosso (CNN-BiLSTM)	MINDS	0.993 ± 0.074	0.993 ± 0.076	0.991 ± 0.008	0.990 ± 0.009
Alves (2024)	MINDS	0.93 ± 0.05	0.94 ± 0.05	0.93 ± 0.05	0.93 ± 0.08
De Castro (2023)	MINDS	0.91 ± 0.07	–	–	0.90 ± 0.08
Passos et al. (2021)	MINDS	0.85 ± 0.02	–	–	–

Tabela 3. Resultados no dataset MINDS + 35 sinais adicionais (média $\pm$ desvio padrão).

Método	Dataset	Acurácia	Precisão	Recall	F1-score
Nosso (CNN-BiLSTM)	MINDS + Adicionados	0.989 ± 0.056	0.989 ± 0.057	0.988 ± 0.061	0.987 ± 0.067

4.4. Comparativo direto: BiLSTM vs. LSTM unidirecional

A Tabela 4 resume as métricas agregadas. O BiLSTM apresenta melhor desempenho global, indicando vantagem da bidirecionalidade em padrões temporais sutis.

Tabela 4. Resumo comparativo entre BiLSTM (nosso) e LSTM unidirecional (média $\pm$ desvio padrão).

Modelo	Acurácia	Precisão (macro)	Recall (macro)	F1 (macro)
CNN-BiLSTM (nosso)	0.993 ± 0.074	0.993 ± 0.076	0.991 ± 0.008	0.990 ± 0.009
LSTM unidirecional	0.9489 ± 0.0101	0.9548 ± 0.0097	0.9567 ± 0.0097	0.9509 ± 0.0104

4.5. Eficiência computacional

O BiLSTM possui **446,499 parâmetros** ($\sim$1,79 MB em FP32) e baixa complexidade (**0,017 GFLOPs** por sequência). Em CPU (*batch*=1, FP32), a latência por etapa é apresentada na Tabela 5, indicando viabilidade em tempo real sem GPU dedicada.

Tabela 5. Desempenho por etapa do pipeline de inferência em CPU (*batch* = 1, FP32; BiLSTM).

Etapa	n	Média (ms)	Mín. (ms)	p50 (ms)	p95 (ms)	Máx. (ms)
Captura	52	9.07	2.10	6.33	12.39	126.01
MediaPipe	52	24.24	15.73	29.91	31.16	37.58
Extração de *features*	52	0.05	0.02	0.05	0.09	0.12
Normalização	52	0.00	0.00	0.00	0.00	0.00
Predição (modelo)	37	41.00	30.32	31.76	34.69	363.57
Renderização	52	0.73	0.40	0.47	0.67	12.96

5. Discussão

Os resultados obtidos demonstram que a arquitetura proposta, combinando **camadas bidirecionais LSTM** para modelagem temporal de sequências de *landmarks* de mãos, oferece alto desempenho com baixo custo computacional. O uso do *MediaPipe Hands* para extração de 21 *landmarks* tridimensionais por mão (totalizando 126 atributos por *frame*)

proporcionou uma entrada compacta, robusta a variações de iluminação, fundo e cor de pele, além de adequada para processamento em tempo real.

Em **Sarmento e Ponti (2023)**, foi observado que, embora abordagens baseadas na combinação de camadas convolucionais e recorrentes alcancem acurácia próxima a 80% quando treino e validação ocorrem no mesmo conjunto, o desempenho cai drasticamente em cenários *cross-dataset*, indicando dificuldades de generalização. Esse estudo também evidenciou que representações baseadas em *landmarks* tendem a superar imagens RGB puras, pela maior robustez frente a variações de captura.

Tabela 6. Avaliação comparativa dos métodos propostos em Sarmento e Ponti (2023).

Feature extractor	# units LSTM	# categ.	Acc.	Top 5 acc.
InceptionResNetV2	128	49	10.2	26.5
MobileNetV2	256	49	8.2	22.4
InceptionResNetV2	512	49	8.2	22.4
Landmark-based	256	49	40.8	75.5
Landmark-based	512	49	40.8	67.3
Landmark-based	128	49	38.8	65.3
Landmark-based	512	33	66.7	93.9
Landmark-based	256	33	63.6	87.9
Landmark-based	128	33	60.6	90.9

Já **Alves et al. (2024)**exploraram arquiteturas multimodais baseadas em *Transformers*, combinando informações de mãos, corpo e expressões faciais. Embora tenham atingido acurácia superior a 93% no dataset MINDS, o custo computacional foi substancialmente maior, exigindo múltiplas fontes de dados e maior capacidade de processamento, o que pode limitar a aplicação em sistemas de baixo custo ou embarcados. Além disso, sua abordagem dependia da biblioteca OpenPose, que apresentava latência elevada, restringindo o uso em tempo real.

De Castro (2023)propôs uma abordagem baseada em CNNs 3D para tradução automática de língua de sinais, obtendo 91% de acurácia no dataset MINDS e 90% de F1-score. Embora o desempenho seja competitivo, o modelo demandava maior capacidade computacional e não foi otimizado para execução em dispositivos embarcados.

Passos et al. (2021), por sua vez, obtiveram 85% de acurácia no dataset MINDS utilizando métodos mais tradicionais, sem explorar arquiteturas otimizadas para sequências temporais de *landmarks*. Esse resultado reforça a evolução da área e o impacto positivo do uso de redes recorrentes especializadas.

A Tabela 7 resume a comparação direta entre esses trabalhos e o presente estudo. Mesmo sem fusão multimodal e utilizando apenas *landmarks* de mãos, o modelo proposto atingiu **99,3%**de acurácia, superando abordagens puramente RGB e aproximando-se, ou mesmo superando, o desempenho de arquiteturas multimodais mais complexas.

Tabela 7. Comparação geral entre trabalhos relacionados e o presente estudo no dataset MINDS.

Trabalho	Arquitetura	Entrada	Acurácia	F1-score
Sarmento; Ponti (2023)	CNN + RNN	Imagem RGB	$\approx 80\%$	N/A
Alves et al. (2024)	Transformer multimodal	Mãos + corpo + face	93 ± 0.05	0.93 ± 0.08
De Castro (2023)	CNN 3D	Vídeo RGB	91 ± 0.07	0.90 ± 0.08
Passos et al. (2021)	Métodos tradicionais	Vídeo RGB	85 ± 0.02	N/A
Presente estudo	**CNN-BiLSTM**	***Landmarks* de mãos**	**99.3**	**0.99**

A principal contribuição deste estudo está na **eficiência e escalabilidade**: com uma arquitetura simples, leve (menos de 1 MB em FP16) e custo computacional extremamente baixo (≈0,017 GFLOPs por amostra), foi possível alcançar acurácia de nível quase *state-of-the-art*, mantendo viabilidade para aplicações em tempo real e dispositivos embarcados, sem depender de múltiplas fontes de captura ou GPUs dedicadas.

Outro aspecto relevante é a **capacidade de generalização** observada nos experimentos. Embora o treinamento tenha sido realizado majoritariamente com a base MINDS, foram também incorporados 35 novos sinais desenvolvidos neste trabalho, resultando em um conjunto expandido. Nesse cenário, o modelo manteve desempenho elevado, obtendo 0.993 ± 0.746 de acurácia e 0.990 ± 0.009 de F1-score, mesmo para sinais que não estavam originalmente presentes no MINDS. Esse resultado sugere que a modelagem baseada em landmarks das mãos apresenta robustez e potencial de adaptação a vocabulários mais amplos, sem degradação significativa do desempenho.

6. Conclusão

O pipeline proposto demonstrou alto desempenho no reconhecimento de sinais isolados de Libras, alcançando acurácia de 99,3% mesmo com conjunto de dados limitado e utilizando apenas *landmarks* das mãos como entrada. A combinação dessa representação compacta com a arquitetura CNN+LSTM resultou em um sistema leve, eficiente e viável para execução próxima ao tempo real, sem necessidade de hardware especializado.

Os resultados mostram que abordagens baseadas exclusivamente em *landmarks* podem alcançar desempenho comparável a métodos mais complexos, mantendo baixo custo computacional e potencial de aplicação prática em tradução automática, ensino de Libras e interfaces acessíveis.

Como trabalhos futuros, destacam-se: adaptação do modelo para dispositivos móveis e embarcados; investigação de fusão multimodal com informações corporais e faciais; personalização para diferentes usuários; integração de aprendizado contínuo; e avaliação do impacto educacional da tecnologia.

Essas direções podem ampliar a robustez do sistema e facilitar sua aplicação em contextos reais de educação, acessibilidade e comunicação.

Referências

[1] World Health Organization. *Deafness and hearing loss*. 2024.

[2] World Federation of the Deaf. *Our Work*. 2016.

[3] Instituto Brasileiro de Geografia e Estatística (IBGE). *Pesquisa Nacional de Saúde 2019: Pessoas com deficiência auditiva*. Tabela 8217 – Pessoas com deficiência auditiva, por sexo e situação do domicílio. Disponível em: `https://www.ibge.gov.br/`. Acesso em: 2026.

[4] Agência Brasil. *Brasil tem mais de 10 milhões de pessoas surdas, segundo o IBGE*. 2022.

[5] Y. Zhang and X. Jiang, "Recent Advances on Deep Learning for Sign Language Recognition," *Computer Modeling in Engineering & Sciences*, vol. 139, no. 3, pp. 2399–2450, 2024.

[6] Fan Zhang, Valentin Bazarevsky, Andrei Vakunov, et al. MediaPipe Hands: On-device Real-time Hand Tracking. 2020.

[7] Google. *MediaPipe Hand Landmarker*. 2025.

[8] Google. *MediaPipe*. 2024.

[9] Tamires Rezende. *MINDS-Libras dataset*. 2021.

[10] Tamires Rezende. *Reconhecimento Automático de Sinais da Libras: Desenvolvimento da Base de Dados MINDS-Libras e Modelos de Redes Convolucionais*. Tese (Doutorado), 2021.

[11] Hossein Vaezi Joze and Oscar Koller. *MS-ASL: A Large-Scale Data Set and Benchmark for Understanding American Sign Language*. 2019.

[12] Dongxu Li, Cristian Rodriguez, Xin Li, et al. *Word-level Deep Sign Language Recognition from Video: A New Large-scale Dataset and Methods Comparison*. 2020.

[13] Abhinav Desai, et al. *ASL Citizen: A Community-Driven Dataset for ASL*. 2023.

[14] Duarte, et al. *(Referência adicionada para resolver citação indefinida)*. 2021.

[15] Shi, et al. *(Referência adicionada para resolver citação indefinida)*. 2022.

[16] D. Kumari and R. S. Anand, "Isolated Video-Based Sign Language Recognition Using a Hybrid CNN-LSTM Framework Based on Attention Mechanism," *Electronics*, vol. 13, no. 7, p. 1229, 2024.

[17] A. H. de A. Sarmento and M. A. Ponti, "A Cross-Dataset Study on the Brazilian Sign Language Translation," in *Proceedings of the ICCV Workshops*, pp. 2816–2825, 2023.

[18] C. E. G. R. Alves, F. A. Boldt and T. M. Paixão, "Enhancing Brazilian Sign Language Recognition through Skeleton Image Representation," *arXiv preprint arXiv:2404.19148*, 2024.